

Лабораторная работа №1: подробный разбор

Что мы делали, зачем и как это повторить

BCR::ABL1 тирозинкиназа — WT и T315I

Шпока Владислав, Пясецкий Кирилл — 4 курс, 3 группа

25 сентября 2026 г.

Зачем этот документ. Отчёт (`report.pdf`) отвечает на вопросы задания и содержит только результат. Здесь — всё остальное: что означает каждый термин, почему выбран тот или иной вариант, откуда взялось каждое число и что отвечать, если на защите спросят «а почему именно так». Документ рассчитан на человека, который открывает эту тему впервые.

Содержание

1	Картина целиком: что вообще происходит в этой работе	2
1.1	Идея за заданием	2
1.2	Почему мишень — BCR::ABL1	2
1.3	Из чего состоит результат	2
2	Биология: минимум, который нужно понимать	2
2.1	Что такое киназа и почему она важна	2
2.2	Нормальная ABL1 и её «предохранители»	3
2.3	Что ломает транслокация t(9;22)	3
2.4	Почему это хорошая мишень	3
2.5	T315I: почему одна буква решает всё	3
3	Базы данных: что где лежит	4
3.1	Что такое «reviewed» в UniProt	4
3.2	Что такое запись PDB и что в ней смотреть	5
3.3	IC ₅₀ , K _i , K _d : в чём разница	5
3.4	Что такое «цензурированное значение»	6
3.5	Что такое SMILES	6
4	Как именно всё было сделано	6
4.1	Шаг 1. UniProt	6
4.2	Шаг 2. Поиск структур в PDB	7
4.3	Шаг 3. Выбор двух структур	7
4.4	Шаг 4. AlphaFold	7
4.5	Шаг 5. Ингибиторы и их активности	8
4.6	Шаг 6. PubChem	8
4.7	Шаг 7. Сборка датасета	8
4.8	Шаг 8. График	9
5	Что отвечать на защите	9
5.1	Вопросы, которые почти наверняка зададут	9
5.2	Термины одной строкой	10

6	Как воспроизвести работу с нуля	11
6.1	Что нужно установить	11
6.2	Порядок запуска	11
6.3	Если что-то не работает	11
7	Что дальше по курсу	11

1 Картина целиком: что вообще происходит в этой работе

1.1 Идея за заданием

Разработка лекарства начинается не с молекулы, а с вопроса «на что воздействовать». Нужно найти белок, чьё изменение вызывает болезнь, — такой белок называют *молекулярной мишенью* (drug target). Дальше нужно убедиться, что по этому белку вообще есть данные, с которыми можно работать на компьютере: известна ли его пространственная структура, есть ли вещества, которые на него действуют, есть ли измеренные числа, описывающие силу этого действия.

Вся работа №1 — это именно такая проверка. Мы ничего не моделируем и не считаем энергии: мы собираем «досье» на мишень и в конце честно отвечаем на вопрос «данных достаточно или нет?». Всё собранное потом используется в следующих работах: структуры — для анализа сайта связывания и докинга, SMILES — для хемоинформатики, числа активности — для сравнения и, возможно, построения моделей.

1.2 Почему мишень — BCR::ABL1

BCR::ABL1 — учебный «идеальный» пример. Для него известно буквально всё: причина возникновения (одна конкретная хромосомная перестройка), болезнь (хронический миелоидный лейкоз), десятки кристаллических структур, шесть одобренных препаратов и тысячи измерений активности. Плюс у него есть знаменитая мутация устойчивости T315I, на которой видно, как *одна* замена аминокислоты обрушивает работу лекарства. Это удобная пара для сравнения: «до» и «после».

1.3 Из чего состоит результат

Что сдаём	Что это
report.pdf	Отчёт по 13 пунктам задания со всеми таблицами
BCR_ABL_dataset.csv	Набор данных: 78 строк, одна строка — одно измерение
BCR_ABL_dataset.xlsx	То же в Excel
figures/fig_activity.png	График сравнения активности WT и T315I
scripts/	Скрипты, которыми всё выгружено
data/	Сырые ответы баз данных в JSON

2 Биология: минимум, который нужно понимать

2.1 Что такое киназа и почему она важна

Киназа — фермент, который переносит фосфатную группу с молекулы АТР на другой белок. Это «выключатель»: у белка появляется заряженная фосфатная группа, он меняет форму и начинает (или перестаёт) работать. Так клетка передаёт сигналы: «расти», «делиться», «двигаться».

Тирозинкиназа — киназа, которая фосфорилирует именно остатки тирозина. ABL1 — *нерецепторная* тирозинкиназа: она не сидит в мембране, а работает внутри клетки.

Ключевой момент: чтобы фосфорилировать что-то, киназе нужен АТР, и он связывается в определённой щели между двумя «долями» белка. Эта щель — **АТР-карман**. Почти все лекарства против киназ — это молекулы, которые занимают этот карман вместо АТР. Отсюда термин *АТР-конкурентный ингибитор*.

Интуиция. Киназа — это «раскладушка» из двух долей (N-доля и C-доля). АТР садится в щель между ними. Лекарство — «пробка», которая эту щель занимает. Дальше вся история про T315I — это история про то, что на входе в щель торчит один остаток, и если он становится больше, пробка перестаёт входить.

2.2 Нормальная ABL1 и её «предохранители»

Здоровая ABL1 не работает постоянно — иначе клетка бы бесконтрольно делилась. У неё есть три механизма самоторможения (в UniProt это раздел *Activity regulation*):

1. на самом N-конце к белку пришит жирнокислотный «хвостик» (миристоил, на остатке Gly2), который вставляется в карман на C-доле киназного домена и фиксирует белок в неактивной форме;
2. домен SH3 прижимается к линкеру между SH2 и киназным доменом — как защёлка;
3. участок CAP (остатки 1–60) дополнительно стабилизирует эту «закрытую» конструкцию.

Когда клетке нужна активность ABL1, защёлки снимаются, петля активации фосфорилируется по Tyr393, и фермент включается.

2.3 Что ломает транслокация t(9;22)

Ген ABL1 лежит на хромосоме 9, ген BCR — на хромосоме 22. Иногда в клетке-предшественнице крови происходит обмен участками между этими хромосомами: **реципрокная транслокация t(9;22)(q34;q11)**. Укороченная хромосома 22 — это и есть *филадельфийская хромосома*. На ней оказывается химерный ген BCR::ABL1.

Что получается на уровне белка:

- ABL1 теряет свой N-конец (остатки 1–26) — а вместе с ним Gly2 и миристоильный «предохранитель»;
- вместо него приделывается кусок BCR, содержащий *coiled-coil* домен — участок, который заставляет молекулы слипаться друг с другом (олигомеризоваться);
- слипшиеся молекулы фосфорилируют друг друга по Tyr393 — киназа включается сама себя и больше не выключается.

Дальше — цепочка: постоянный сигнал → постоянное фосфорилирование белков-посредников (CRKL, STAT5 и др.) → активация путей роста (RAS/MAPK, PI3K/AKT, JAK/STAT) → миелоидные клетки делятся без внешней команды и не умирают → хронический миелоидный лейкоз.

Что важно для отчёта (пункт 2 задания): преподаватель хочет увидеть не пересказ учебника про лейкоз, а именно эту логическую цепочку из шести звеньев. В отчёте она оформлена таблицей «Этап — Содержание».

2.4 Почему это хорошая мишень

Три причины, которые стоит назвать:

1. **Драйверная мутация.** Не «один из факторов», а единственная причина болезни. Подавили белок — остановили болезнь.
2. **Избирательность.** Патологический белок есть только в опухолевых клетках; нормальные клетки его не содержат, значит, у лекарства есть шанс быть не слишком токсичным.
3. **«Друггабельность».** У белка есть готовый, хорошо очерченный карман для малой молекулы (АТР-карман). Это редкость — многие важные белки (например, транскрипционные факторы) карманов не имеют, и подобрать к ним молекулу почти невозможно.

2.5 T315I: почему одна буква решает всё

Обозначение. T315I читается так: в положении 315 был Thr (треонин, T), стал Ile (изолейцин, I). Аминокислоты обозначаются либо тремя буквами (Thr), либо одной (T).

Где этот остаток. В самом конце «шарнира» (hinge) — петли, соединяющей две доли киназы, прямо на входе в АТР-карман. В UniProt сайт связывания АТР указан как 316–322, то есть 315-й стоит вплотную перед ним.

Почему «gatekeeper» (привратник). За АТР-карманом есть дополнительная полость — *back pocket*, или «задний карман». Многие ингибиторы (иматиниб, нилотиниб) не помещаются в один только АТР-карман: часть их молекулы уходит в заднюю полость. Пройдёт ли молекула туда, зависит от размера боковой цепи остатка 315: он стоит ровно в проходе. Маленький треонин — проход открыт; крупный изолейцин — закрыт.

Два эффекта замены:

1. *Потеря водородной связи.* У треонина в боковой цепи есть группа $-OH$, которая образует водородную связь с молекулой ингибитора. У изолейцина (углеводородная боковая цепь) образовать такую связь нечем.
2. *Стерическое препятствие.* Изолейцин объёмнее: примерно $167 \text{ \AA}^3$ против $116 \text{ \AA}^3$. Лишние атомы занимают место, где раньше лежала часть молекулы ингибитора.

Эффект второй причины сильнее. Потеря одной Н-связи (4–8 кДж/моль) изменила бы аффинность в несколько раз: связь между энергией и константой связывания — логарифмическая, $\Delta G = -RT \ln K$, и при комнатной температуре $RT \approx 2,5$ кДж/моль, так что 6 кДж/моль дают примерно десятикратное изменение. А наблюдаемое падение для дазатиниба — в десятки тысяч раз. Значит, дело не в энергетике одной связи, а в том, что молекула *геометрически* не помещается.

Кто выживает при T315I:

- **Понатиниб** — в его молекуле есть линейный фрагмент с тройной связью ($C\#C$ в SMILES), тонкий как игла. Он проходит мимо увеличенного изолейцина, не упираясь в него.
- **Асциминиб** — вообще не садится в АТР-карман. Он занимает тот самый миристоильный карман, куда в здоровом белке вставляется жирный «хвостик». Этот механизм назван STAMP (*Specifically Targeting the ABL Myristoyl Pocket*). Мутация в АТР-кармане ему просто безразлична.
- **Аксетиниб** — препарат, изначально разработанный против другой киназы (VEGFR) и одобренный для рака почки. Выяснилось, что против T315I он работает *лучше*, чем против нормального ABL1. Это классический пример *перепрофилирования* (drug repurposing).

3 Базы данных: что где лежит

База	Что хранит	Что мы взяли
UniProt	Белки: последовательность, домены, функции, болезни	Запись P00519: длина 1130 а.о., киназный домен 242–493, сайты АТР, точка разрыва 26/27
RCSB PDB	Экспериментальные 3D-структуры (координаты атомов)	109 записей, связанных с ABL1; 68 с киназным доменом; выбрали 2HYY и 3QRJ
AlphaFold DB	Предсказанные нейросетью структуры	Модель AF-P00519-F1, покрывает остатки 1–1130
ChEMBL	Биоактивности из статей: IC_{50} , K_i , K_d	78 измерений для 7 соединений против WT и T315I
BindingDB	То же, с уклоном в данные связывания	Использована как перекрёстная проверка
PubChem	Химические вещества: структуры, идентификаторы	CID, формула, масса, SMILES для 7 соединений

3.1 Что такое «reviewed» в UniProt

UniProt состоит из двух частей. **Swiss-Prot** (помечено *reviewed*, значок с галочкой) — записи, которые вручную проверил куратор: функции подтверждены ссылками на статьи, домены размечены. **TrEMBL** (*unreviewed*) — автоматически сгенерированные записи, их на порядки больше и качество ниже. Задание требует именно reviewed-запись, поэтому мы берём ABL1_HUMAN / P00519.

3.2 Что такое запись PDB и что в ней смотреть

Одна запись PDB — это результат *одного эксперимента*: конкретный белок (часто только его фрагмент), возможно с конкретным лигандом, закристаллизованный в конкретных условиях. Поэтому у одного белка бывают десятки записей. Смотреть нужно на:

Поле	Что означает
Experimental Method	X-ray diffraction (рентген), NMR (ЯМР), cryo-EM. Для нашей задачи лучше рентген: даёт точные координаты и лиганд
Resolution	Разрешение в ангстремах. <i>Меньше — лучше</i> . До 2.0 Å — хорошо, 2.0–2.5 — приемлемо, хуже 3.0 — положение отдельных боковых цепей уже ненадёжно
Ligands	Малые молекулы в структуре. Отличайте лекарство от «мусора»: SO ₄ , GOL (глицерин), CL, NA — это соли и криопротектор из буфера, а не лиганд
Macromolecules / Entity	Какой кусок белка есть в структуре (например, 229–500 — только киназный домен)
Mutation(s)	Введённые замены. Бывает, что кроме нужной T315I есть ещё лишние — такие структуры хуже

Ловушка, на которую легко попасть. В поле «Mutation» часть записей пишет YES без расшифровки (так в 2V7A), а часть использует нумерацию другой изоформы: в 5M04 стоит T334I, и это *та же самая* мутация T315I, просто отсчёт начинается на 19 остатков раньше. Поэтому в работе мы определяли форму белка не по этому полю, а по самой последовательности — см. раздел 4.

3.3 IC₅₀, K_i, K_d: в чём разница

Это три разных числа, и путать их нельзя.

Вел.	Определение	Особенности
K _d	Константа диссоциации комплекса белок–лиганд	Чистая термодинамика: насколько прочно молекула держится. Не зависит от АТР
K _i	Константа ингибирования	Похожа на K _d , но получена из кинетики фермента
IC ₅₀	Концентрация, при которой активность фермента падает вдвое	Зависит от условий: концентрации АТР, времени инкубации, субстрата. В разных лабораториях будет разной

Во всех трёх случаях *меньше — значит сильнее*. 1 нМ — очень сильный ингибитор, 1000 нМ (= 1 мкМ) — слабый.

Связь IC₅₀ и K_i для конкурентного ингибитора даёт уравнение Ченга–Прусоффа:

$$K_i = \frac{IC_{50}}{1 + [АТР]/K_m}.$$

Отсюда видно, почему две лаборатории получают разные IC₅₀: если у одной в пробе 10 мкМ АТР, а у другой 1 мМ, числа разойдутся в десятки раз при одинаковой реальной силе связывания.

Это — ответ на вопрос в пункте 8 задания («можно ли сравнивать все найденные значения напрямую?»). Нет, нельзя: разные величины, разные условия, разные конструкции белка. Сравнить можно только внутри одной публикации и одного типа анализа. В нашем наборе IC₅₀ иматиниба против WT меняется от 75 до 7700 нМ — сто раз разницы, и это при

одном и том же веществе и одной и той же мишени.

3.4 Что такое «цензурированное значение»

В таблицах встречается >10000 нМ. Это не измеренная величина, а граница: «в исследованном диапазоне концентраций (до 10 мкМ) подавления не увидели». Настоящее значение может быть 20 мкМ, а может 500 мкМ — мы не знаем. Такие данные:

- *нельзя* подставлять в регрессию как число;
- *нужно* сохранять со знаком «>», а не молча превращать в 10000.

Именно поэтому в нашем датасете в столбце `Activity_value` стоит строка >10000, а не число.

3.5 Что такое SMILES

SMILES (*Simplified Molecular Input Line Entry System*) — способ записать молекулу одной строкой. Читается примерно так:

Фрагмент	Значение
C, N, O	атомы углерода, азота, кислорода (водороды подразумеваются)
c1ccccc1	ароматическое кольцо (строчные буквы = ароматика)
C1CCCCC1	обычный цикл: цифры отмечают, где кольцо замыкается
= #	двойная и тройная связь
()	ответвление
/C=C/	конфигурация двойной связи (<i>E</i> или <i>Z</i>)
[C@OH]	стереоцентр (хиральный атом) с указанием ориентации

Например, у понатиниба в SMILES есть C#CC4=CN=C5N4N=CC=C5 — это та самая «игла» с тройной связью, которая позволяет ему обходить мутировавший gatekeeper. То есть по строке SMILES уже можно кое-что сказать о механизме.

Почему SMILES нужен. Компьютер не умеет работать с названием «иматиниб» — это просто слово. А SMILES — это полное описание молекулярного графа: любая библиотека (RDKit, Open Babel) прочтает его, построит 2D- или 3D-структуру, посчитает дескрипторы и отпечатки, оценит сходство молекул. И всё это помещается в одну ячейку таблицы — в отличие от файла координат.

4 Как именно всё было сделано

Этот раздел — воспроизводимая инструкция. Все шаги можно повторить как руками через сайты, так и скриптами из папки `scripts/`.

4.1 Шаг 1. UniProt

Руками: зайти на <https://www.uniprot.org>, ввести *ABL1 human*, выбрать запись с пометкой *Reviewed* и названием *ABL1_HUMAN*. Нужные поля находятся в разделах *Names & Taxonomy*, *Function*, *Family & Domains*, *Sequence*.

Скриптом: `python scripts/fetch_uniprot.py`. Скрипт обращается к <https://rest.uniprot.org/uniprotkb/P00519.json> и печатает всё разом.

Что получили:

- длина 1130 а.о.; киназный домен 242–493; SH3 61–121; SH2 127–217;
- сайты связывания АТР: 248–256, 271, 316–322; каталитический Asp363;
- точка разрыва при транслокации: между 26 и 27 остатком (прямо в записи!);
- остаток 315 — действительно Thr, окружение TREPPFYIITEFMTYGNLLD.

Подводный камень: нумерация. У ABL1 две изоформы. Изоформа 1a — 1130 остатков, gatekeeper = Thr315. Изоформа 1b на 19 остатков длиннее, там тот же остаток — Thr334. В литературе и в PDB используются обе. Мы везде работаем в нумерации 1a (как в UniProt P00519-1) и оговариваем это в отчёте.

4.2 Шаг 2. Поиск структур в PDB

Руками: на <https://www.rcsb.org> искать *ABL1 kinase* и *ABL1 T315I*, затем открывать записи и смотреть поля из таблицы выше.

Скриптом: `python scripts/survey_pdb.py`. Логика:

1. через Search API найти все записи, ссылающиеся на UniProt P00519 (человек) и P00520 (мышь) — получилось 109;
2. через Data API (GraphQL) забрать по ним метаданные, включая последовательность;
3. определить форму белка *по последовательности*: если в ней есть мотив FYIITEF — это WT, если FYIIIEF — T315I. Третья буква I вместо T — это и есть мутация.

Почему именно так, а не по полю «Mutation». Как уже сказано, поле заполнено непоследовательно: где-то YES, где-то T334I. А последовательность есть всегда и не врёт. Заодно этот же критерий отсеивает записи, где киназного домена вообще нет (структуры отдельных SH3/SH2-доменов или комплексов с ДНК): если мотива нет ни в каком виде, значит остаток 315 в структуру не попал.

Результат: 68 записей содержат киназный домен; из них 60 — WT, 8 — T315I; 64 из 68 содержат связанную малую молекулу; 65 получены рентгеном, 3 — ЯМР. Эти числа попали в отчёт и в итоговый вывод.

4.3 Шаг 3. Выбор двух структур

Критерии из задания и как мы их применили:

Критерий	Как проверяли
Содержит ABL kinase domain	Проверено по выравниванию: 2HYY — остатки 228–500, 3QRJ — 229–499
Есть известный ингибитор	2HYY: STI (иматиниб); 3QRJ: 919 (ребастиниб)
Хорошие экспериментальные характеристики	2HYY — 2.40 Å, 3QRJ — 1.82 Å (лучшее разрешение среди всех структур T315I)
Нужная форма белка	2HYY — Thr315; 3QRJ — Ile315 (по последовательности)
Нет лишних мутаций	Обе записи «чистые». Для сравнения: 5MO4 содержит ещё и D363N (инактивация катализа), 3DK7 — L445P
Полный сайт связывания	В обеих структурах лиганд разрешён целиком
Человеческий белок	Обе — <i>Homo sapiens</i> . Это важно: 1IEP, 3IK3, 3OY3, 2Z60 — мышинные

Итог: 2HYY (WT) и 3QRJ (T315I).

Что можно ответить, если спросят про альтернативу. Пара 4WA9/4TWP тоже хороша — это WT и T315I с одним и тем же лигандом (аксетинибом), полученные в одной работе. Её плюс: любые различия между структурами почти наверняка вызваны мутацией, а не разными лигандами. Минус: разрешение хуже (2.20 и 2.40 Å), и 2HYY — гораздо более цитируемый эталон для АТР-кармана. Мы выбрали 2HYY/3QRJ, а 4WA9/4TWP держим как контрольную пару.

4.4 Шаг 4. AlphaFold

Открывается напрямую: <https://alphafold.ebi.ac.uk/entry/P00519>. Модель AF-P00519-F1, покрывает всю последовательность 1–1130.

Что тут важно понять — разницу трёх типов данных:

	Что это	Чего там нет
Sequence (UniProt)	Порядок аминокислот, аннотации	Нет координат вообще
Structure (PDB)	Реально измеренные координаты атомов	Обычно только фрагмент белка
Prediction (AlphaFold)	Предсказанные координаты для всей цепи	Нет лигандов, ионов, воды; нет разрешения; одна усреднённая конформация

Готовой модели *BCR::ABL1 T315I* в AlphaFold DB нет и быть не может: база строится по референсным протеомам, а слитный белок — продукт соматической перестройки в опухолевой клетке, его нет в «нормальном» геноме. Мутантную модель при необходимости строят сами.

4.5 Шаг 5. Ингибиторы и их активности

Руками: в ChEMBL найти соединение (например, *imatinib*), открыть вкладку *Activities*, отфильтровать по мишени *ABL1* и по типу показателя.

Скриптом: `python scripts/fetch_chembl.py`. Запрос идёт к `https://www.ebi.ac.uk/chembl/api/data/activity` с параметрами `molecule_chembl_id`, `target_chembl_id` и `standard_type__in=IC50,Ki,Kd`.

Две мишени в ChEMBL:

- ChEMBL1862 — ABL1, изолированная киназа;
- ChEMBL2096618 — BCR-ABL1, слитный белок.

Форму (WT или мутант) даёт поле `assay_variant_mutation`: пусто — WT, T315I — мутант. Есть и другие мутанты (E255K, Y253H, F317L...) — их мы отбросили, они не входят в задание.

Почему выбрали именно эти семь соединений. Нужно было показать разное поведение относительно T315I:

- иматиниб, нилотиниб, дазатиниб — теряют активность полностью;
- бозутиниб — теряет частично (интересный промежуточный случай);
- понатиниб — сохраняет (АТР-конкурентный, но «обходит» gatekeeper);
- асциминиб — сохраняет (другой сайт связывания);
- аксетиниб — парадокс: против мутанта активнее, чем против нормы.

Честный пробел. Для асциминива в ChEMBL не нашлось записи с явной пометкой T315I, хотя из литературы известно, что он против этого мутанта работает. В отчёте так и написано: «не найдено», с указанием, где искали. Задание это прямо разрешает, и это правильнее, чем подставить число «по памяти».

4.6 Шаг 6. PubChem

`python scripts/fetch_pubchem.py` — запрос к PUG REST API по названию вещества, свойства `MolecularFormula`, `MolecularWeight`, `SMILES`, `InChIKey`.

Для асциминива и аксетинива важно брать *изомерный* SMILES: у первого есть стереоцентр (`[C@H]`), у второго — *E*-конфигурация двойной связи (`/C=C/`). Если взять запись без стереохимии, это будет уже, строго говоря, другое вещество.

4.7 Шаг 7. Сборка датасета

`python scripts/build_dataset.py` объединяет загрузки в таблицу с колонками из задания. Ключевые решения:

Решение	Почему
Одна строка — одно измерение	Так требует задание, и так правильно: усреднять значения из разных анализов нельзя (см. Ченга–Прусоффа)
Только отобранные публикации	Иначе в набор попадают случайные клеточные анализы без привязки к форме мишени
Знак «>» сохраняется	Цензурированные данные остаются видимыми
PDB_ID где возможно	Связывает число с конкретной структурой; если такой структуры нет — поле пустое, а не выдуманное
Source с PMID	Любое число можно проверить по первоисточнику
Разделитель «;», UTF-8 с BOM	Чтобы русский Excel открыл файл сразу и по столбцам

Получилось 78 строк: 42 для WT и 36 для T315I, 7 соединений, 11 первоисточников.

4.8 Шаг 8. График

`python scripts/plot_activity.py` строит столбчатую диаграмму: по одному столбцу WT и T315I на каждое соединение.

Три решения, которые стоит уметь объяснить:

1. **Логарифмическая шкала по оси Y.** Значения различаются в 10^4 раз. На линейной шкале все столбцы, кроме дазатиниба против T315I, слились бы в одну линию у нуля.
2. **Медиана, а не среднее.** Измерений на соединение несколько, и они из разных статей; одно выбивающееся значение (7700 нМ для иматиниба) сдвинуло бы среднее, а медиана устойчива.
3. **Знак «>» над столбцом.** Если среди измерений есть цензурированные, столбец — это заниженная оценка. Не пометить это — значит соврать в графике.

Что видно на графике. Иматиниб, нилотиниб, дазатиниб — огромный скачок вверх (потеря активности). Бозутиниб — умеренный. Понатиниб — почти ничего. Аксетиниб — столбец T315I ниже столбца WT. Вывод в одну фразу: T315I — не «общее ухудшение связывания», а избирательный эффект, зависящий от того, опирается ли молекула на контакт с gatekeeper-остатком.

5 Что отвечать на защите

5.1 Вопросы, которые почти наверняка зададут

Почему вы работаете с ABL1, а не с BCR::ABL1? Потому что патологическая активность целиком определяется киназным доменом ABL1, все ингибиторы связываются в нём, мутация T315I — в нём же, и структурных данных по полноразмерному слитному белку просто не существует.

Что означает WT в этой работе? Форма киназного домена *без мутации T315I*. Это не значит «нормальный физиологический белок»: BCR::ABL1 патологичен в любом случае. WT здесь — условное обозначение из задания.

Почему выбрали 2HYY и 3QRJ? Обе — человеческий киназный домен без посторонних мутаций, обе с ингибитором в структуре, у 3QRJ лучшее разрешение среди всех T315I-структур (1.82 Å), 2HYY — канонический эталон комплекса с иматинибом.

Почему у вас в таблице стоит «>10000», а не число? Это цензурированное значение: эксперимент показал только, что в исследованном диапазоне подавления нет. Подставлять сюда 10000 как измеренную величину было бы ошибкой.

Можно ли сравнивать IC₅₀ из разных статей? Нет. IC₅₀ зависит от концентрации АТР (Ченг–Прусофф), формата анализа и конструкции белка. В нашем наборе одно и то же веще-

ство против одной и той же мишени даёт разброс в 100 раз. Сравнивать можно только внутри однородной группы.

Почему у аксетиниба активность против мутанта выше? Он связывается в конформации, которая не требует прохода за gatekeeper, и, по-видимому, лучше подходит именно к геометрии мутантного кармана. Это экспериментальный факт из работы 2015 года (PMID 25686603), подтверждённый структурами 4WA9 и 4TWP.

Чем асциминиб отличается от остальных? Он не АТР-конкурентный. Он занимает миристоильный карман — то место, куда в здоровом белке вставляется N-концевой жирный «хвостик», и восстанавливает автоингибирование. Поэтому мутации в АТР-кармане на него не влияют.

Достаточно ли данных для дальнейшей работы? Да, но с оговорками: структур T315I в 7,5 раза меньше, чем WT; часть данных активности цензурирована; значения из разных источников несопоставимы напрямую; модели слитного белка нет.

5.2 Термины одной строкой

Термин	Значение
Drug target	Молекула (обычно белок), на которую направлено действие лекарства
Киназа	Фермент, переносящий фосфат с АТР на белок-мишень
Kinase domain	Каталитическая часть киназы; у ABL1 — остатки 242–493
АТР-карман	Щель между долями киназы, где связывается АТР; сюда садятся ингибиторы
Gatekeeper	Остаток на входе в заднюю полость кармана; у ABL1 это Thr315
Back pocket	Дополнительная гидрофобная полость за gatekeeper
DFG-in / DFG-out	Две конформации петли активации (по мотиву Asp-Phe-Gly): активная и неактивная. Ингибиторы типа I связывают DFG-in, типа II — DFG-out
Петля активации	Участок 381–405; фосфорилирование Tyr393 включает киназу
Миристоильный карман	Полость на C-доле, куда вставляется N-концевой жирный «хвостик»; сайт связывания асциминиба
Fusion gene	Химерный ген из двух разных генов после хромосомной перестройки
t(9;22)	Транслокация, дающая филадельфийскую хромосому и ген BCR::ABL1
TKI	Tyrosine Kinase Inhibitor — ингибитор тирозинкиназы
IC ₅₀	Концентрация, снижающая активность фермента вдвое
K _d / K _i	Константы диссоциации комплекса / ингибирования
Цензурированное значение	Граница вида «>10000», а не измеренное число
SMILES	Строковая запись структуры молекулы
InChIKey	Хешированный идентификатор молекулы фиксированной длины
PDB ID	Четырёхсимвольный код записи в Protein Data Bank (например, 2HYY)
Resolution	Разрешение структуры в ангстремах; меньше — лучше
Apo / holo	Структура без лиганда / с лигандом
pLDDT, PAE	Оценки достоверности предсказания AlphaFold (разбираются в другой работе)
Редокинг	Проверка протокола докинга: лиганд вынимают из структуры и пытаются вернуть на место

6 Как воспроизвести работу с нуля

6.1 Что нужно установить

Компонент	Зачем
Python 3.8+	Запуск скриптов; хватает стандартной библиотеки
matplotlib, numpy	Построение графика: <code>pip install matplotlib numpy</code>
openpyxl (необязательно)	Сохранение .xlsx; без него делается только .csv
MiKTeX / TeX Live	Сборка отчёта в PDF

6.2 Порядок запуска

№	Команда	Что получится
1	<code>python scripts/fetch_uniprot.py</code>	<code>data/uniprot_P00519.json</code> , данные для таблицы раздела 1
2	<code>python scripts/survey_pdb.py</code>	<code>data/abl_rows.json</code> , статистика по структурам
3	<code>python scripts/fetch_chembl.py</code>	<code>data/chembl_activities.json</code>
4	<code>python scripts/fetch_pubchem.py</code>	<code>data/pubchem.json</code>
5	<code>python scripts/build_dataset.py</code>	<code>BCR_ABL_dataset.csv</code> и <code>.xlsx</code>
6	<code>python scripts/plot_activity.py</code>	<code>figures/fig_activity.png</code>
7	<code>cd report && pdflatex report.tex</code> (дважды)	<code>report.pdf</code>

Почему pdflatex запускают дважды. При первом проходе LaTeX собирает номера разделов, ссылок и страниц во вспомогательный файл `.aux`, при втором — подставляет их в текст. После одного прохода вместо номеров разделов будут вопросительные знаки.

6.3 Если что-то не работает

Симптом	Что делать
<code>socket.timeout</code> при обращении к ChEMBL	Сервер отвечает медленно; в скрипте уже есть повторы. Запустить ещё раз
В Excel вся строка в одной ячейке	Файл открыт с неверным разделителем. Данные → Текст по столбцам → разделитель «;». Или открыть .xlsx
Кракозябры вместо русского в CSV	Нужна кодировка UTF-8; файл уже сохранён с BOM, но старые версии Excel всё равно просят указать ручную
<code>! LaTeX Error: File ... not found</code>	MiKTeX докачивает пакеты при первой сборке — разрешить установку и пересобрать
Вместо русского в PDF пустоты	Не подключены <code>fontenc[T2A]</code> и <code>babel[russian]</code> — в наших файлах они есть, проверить преамбулу

7 Что дальше по курсу

Собранное здесь — вход для следующих работ:

Что понадобится	Где будет использоваться
PDB 2HYU и 3QRJ	Анализ структуры белка, подготовка рецептора, определение binding site, докинг
SMILES семи соединений	Хемоинформатика: дескрипторы, отпечатки, сходство; подготовка лигандов
BCR_ABL_dataset.csv	Сравнение расчётных и экспериментальных величин; возможно, QSAR
Понимание T315I	Объяснение, почему докинг иматиниба в 3QRJ должен давать худший результат, чем в 2HYU
AlphaFold-модель	Отдельная работа про pLDDT, PAE и надёжность предсказаний

Главное, что стоит запомнить из этой работы: прежде чем что-то считать, нужно понять, из чего сделаны исходные данные. Числа из баз — не абсолютная истина: у них есть метод получения, условия эксперимента, единицы измерения и ограничения. Работа №1 — как раз про то, чтобы научиться это видеть.