

Гайд к лабораторной работе №2

Экспериментальные структуры белка: как их читать, проверять и готовить к докинг

На примере киназного домена ABL1: 2HYU (WT) и 3QRJ (T315I)

Шпока Владислав, Пясецкий Кирилл

4 курс, 3 группа

4 октября 2026 г.

Содержание

1	Зачем вообще нужна эта работа	3
2	Теория: что такое PDB-структура	3
2.1	Откуда берутся координаты	3
2.2	Разрешение и что оно значит	3
2.3	B-фактор	4
2.4	Почему в структуре не хватает кусков	4
2.5	Что ещё лежит в файле, кроме белка	4
2.6	Формат АТОМ-записи	4
3	Теория: нумерация остатков — главный источник ошибок	5
3.1	Откуда берётся расхождение	5
3.2	Как проверять, а не угадывать	5
4	Теория: наложение структур и RMSD	6
4.1	Что считает Matchmaker	6
4.2	Как строятся пары остатков	6
4.3	Итеративное отбрасывание и почему RMSD два	7
5	Что именно сделано в работе, шаг за шагом	7
5.1	Инструменты	7
5.2	Шаг 1. Загрузка	7
5.3	Шаг 2. Выбор цепи	7
5.4	Шаг 3. Проверка полноты	8
5.5	Шаг 4. Поиск остатка 315 и проверка нумерации	8
5.6	Шаг 5. Лиганд и сайт связывания	8
5.7	Шаг 6. Сохранение рабочих файлов	8
5.8	Шаг 7. Наложение	9

6	Главный результат и как его интерпретировать	9
6.1	Структуры почти одинаковы	9
6.2	Но различия есть, и они не там, где мутация	10
6.3	Почему глобальное RMSD обманчиво	11
7	Разбор кода	12
7.1	Структура проекта	12
7.2	Поиск пропусков	12
7.3	Остатки сайта связывания	12
7.4	Наложение Кабша	12
7.5	Итеративное отбрасывание	13
8	Как повторить всё с нуля	13
9	Честные ограничения работы	14
10	Вероятные вопросы на защите	15
11	Выводы	15

1 Зачем вообще нужна эта работа

В первой лабораторной мы выяснили, *что* является мишенью: белок ABL1 (UniProt P00519), его киназный домен 242–493, мутация T315I в gatekeeper-остатке, и выбрали две структуры — **2HYU** для WT и **3QRJ** для T315I. Но сами координаты мы тогда не трогали: работали с аннотациями баз данных.

Вторая работа — это переход от «записи в базе» к «файлу, с которым можно считать». Цель: получить из публичной записи PDB такой набор файлов, который можно подать на вход докингу, и при этом быть уверенным, что мы понимаем, что именно в этих файлах лежит.

Ключевая мысль работы: **экспериментальная структура — это не точная копия белка, а модель, построенная по электронной плотности**. В ней может не хватать кусков цепи, могут быть лишние молекулы из буфера, нумерация может не совпадать с UniProt, а «тот же самый белок» в двух записях может выглядеть по-разному из-за разных лигандов. Всё это нужно проверить руками до того, как запускать расчёты.

2 Теория: что такое PDB-структура

2.1 Откуда берутся координаты

Подавляющее большинство структур белков получено **рентгеновской дифракцией** (X-ray diffraction). Схема такая:

1. Белок очищают и заставляют кристаллизоваться — образовать регулярную трёхмерную решётку из миллионов одинаково ориентированных молекул.
2. Кристалл облучают рентгеном. Электроны атомов рассеивают излучение, и из-за регулярности решётки рассеянные волны интерферируют: на детекторе появляется набор дискретных рефлексов.
3. По интенсивностям рефлексов восстанавливают **карту электронной плотности** — трёхмерную функцию «где в ячейке много электронов».
4. В эту карту *вписывают* модель: исследователь (и программа) размещают атомы так, чтобы они объясняли наблюдаемую плотность.

Последний пункт принципиален: координаты в PDB-файле — это *интерпретация* плотности, а не прямое измерение положения каждого атома.

2.2 Разрешение и что оно значит

Разрешение (resolution, в ангстремах) — минимальное расстояние, на котором две детали карты ещё различимы. Чем меньше число, тем лучше:

Разрешение	Что видно
лучше 1,5 Å	Отдельные атомы, альтернативные конформации боковых цепей, много упорядоченной воды
1,5–2,0 Å	Боковые цепи уверенно различимы, положение лиганда надёжно — <i>хороший уровень для докинга</i>
2,0–2,5 Å	Основная цепь надёжна, некоторые боковые цепи на поверхности неоднозначны
хуже 3,0 Å	Виден в основном ход цепи; детали карманов ненадёжны

Наши структуры: 2HYY — 2,40 Å (приемлемо), 3QRJ — 1,82 Å (хорошо). Именно поэтому в 3QRJ разрешено в 2,5 раза больше молекул воды, хотя цепей меньше: при лучшем разрешении различимо больше упорядоченного растворителя.

2.3 В-фактор

У каждого атома в файле есть **В-фактор** (temperature factor) — мера «размазанности» атома по карте плотности. Высокий В означает, что атом подвижен или его положение определено плохо. В нашем примере у N-концевого Trp235 В-фактор равен 89 — это очень много, типично для края конструкции, который болтается. У атомов в глубине кармана В обычно 15–30.

Практический смысл: если остаток сайта связывания имеет В-фактор под 80, доверять его точной геометрии не стоит.

2.4 Почему в структуре не хватает кусков

Если участок цепи подвижен (петля, не зафиксированная контактами), он не даёт регулярного вклада в плотность — плотности там просто нет, и вписать атомы некуда. Такие остатки в файл не попадают: в последовательности они есть, а координат у них нет. Это и есть **missing residues**, пропуски.

Важное следствие: **нумерация остатков не непрерывна**. После остатка 273 может сразу идти 279. Если наивно пройтись по файлу подряд, можно «склеить» несоседние остатки.

2.5 Что ещё лежит в файле, кроме белка

- **Лиганд** — интересующая нас малая молекула (ингибитор). У неё есть трёхсимвольный код химического компонента: STI — иматиниб, 919 — ребастиниб.
- **Вода** (HON) — упорядоченные молекулы растворителя.
- **Ионы и добавки** — Na⁺, Mg²⁺, Ni²⁺, глицерин, сульфат: попадают из буфера кристаллизации. В наших структурах их нет.
- **Несколько копий белка** — в асимметричной ячейке может быть несколько молекул (в 2HYY — четыре цепи A, B, C, D). Это кристаллографическая особенность, а не биологический тетрамер.

2.6 Формат АТОМ-записи

Классический PDB — формат с *фиксированными колонками*: смысл поля определяется его позицией в строке, а не разделителем.

ATOM	1	N	TRP	A	235	2.281	3.258	18.672	1.00	89.25	N
------	---	---	-----	---	-----	-------	-------	--------	------	-------	---

Колонки	Поле	Пояснение
1–6	тип записи	АТОМ — полимер, НЕТАТМ — всё остальное
7–11	номер атома	сквозная нумерация по файлу
13–16	имя атома	N, CA, CB, OG1...
18–20	имя остатка	трёхбуквенный код
22	цепь	A
23–26	номер остатка	в системе нумерации записи
31–38	X	ангстремы
39–46	Y	
47–54	Z	
55–60	оссурансу	доля конформации (1.00 — единственная)
61–66	B-фактор	подвижность
77–78	элемент	N, C, O, S

Современный формат — **mmCIF** (.cif): это таблицы «ключ–значение» без ограничения на ширину поля. PDB-формат ломается на структурах с числом атомов больше 99999 или числом цепей больше 62, поэтому RCSB считает mmCIF основным. Мы скачиваем .cif, а рабочие файлы сохраняем в .pdb, потому что программы докинга чаще ждут именно его.

3 Теория: нумерация остатков — главный источник ошибок

3.1 Откуда берётся расхождение

Номер остатка в PDB-файле — это то, что авторы структуры написали в своей статье. Он не обязан совпадать с позицией в канонической последовательности UniProt. Причины расхождений:

1. **Разные изоформы.** У ABL1 есть изоформа 1a (1130 а.о., P00519-1) и 1b (на 19 остатков длиннее). Один и тот же gatekeeper в первой нумерации — Thr315, во второй — Thr334. В литературе встречаются обе; запись 5M04 из первой лабораторной, например, обозначает мутацию как T334I.
2. **Другой организм.** Мышиный ортолог (P00520) имеет свою нумерацию.
3. **Искусственные конструкции.** Если белок экспрессировали с меткой (His-tag), авторы иногда нумеруют с учётом метки.

3.2 Как проверять, а не угадывать

Нельзя полагаться на то, что «остаток 315 — это Thr315». Нужно сопоставить *последовательность*. Надёжный способ, использованный в работе: перебрать все возможные сдвиги и посмотреть, при каком из них последовательность структуры лучше всего ложится на последовательность UniProt.

```
# for each candidate shift, count how many residues match UniProt
best = (0, -1.0)
for offset in range(-40, 41):
```

```

hit = total = 0
for num, name in residues:      # (seqid, 3-letter name) from the chain
    pos = num + offset
    if 1 <= pos <= len(useq):
        total += 1
        if one_letter(name) == useq[pos - 1]:
            hit += 1
if total and hit / total > best[1]:
    best = (offset, hit / total)

```

Результат для наших структур: сдвиг **0** для обеих. Доля совпадений 100 % для 2HYU и 99,6 % для 3QRJ.

Почему 99,6 %, а не 100 % — это не ошибка, а проверка. Единственное несовпадение в 3QRJ приходится ровно на остаток 315: в UniProt там T, в структуре I. Мутация честно проявилась как одно расхождение. Заодно это доказывает, что *других* замен в структуре нет: будь их больше, несовпадений было бы больше одного.

4 Теория: наложение структур и RMSD

4.1 Что считает Matchmaker

Чтобы сравнить две структуры, их нужно привести в одну систему координат. Задача: найти поворот R и сдвиг t , минимизирующие сумму квадратов расстояний между соответственными атомами. Это классическая **задача Кабша**, решаемая через сингулярное разложение:

1. Совместить центры масс обоих наборов точек.
2. Построить ковариационную матрицу $H = P^T Q$.
3. Разложить $H = U \Sigma V^T$; тогда $R = V D U^T$, где $D = \text{diag}(1, 1, \text{sign det}(V U^T))$ — поправка, запрещающая зеркальное отражение.

Мера качества — **RMSD** (root-mean-square deviation):

$$\text{RMSD} = \sqrt{\frac{1}{N} \sum_{i=1}^N \|\mathbf{p}_i - \mathbf{q}_i\|^2}$$

То есть среднеквадратичное расстояние между парами соответственных атомов после наилучшего совмещения. Обычно считают по $C\alpha$ — по одному опорному атому на остаток.

4.2 Как строятся пары остатков

ChimeraX по умолчанию (`pairing ss`) сначала выравнивает последовательности с учётом вторичной структуры, и уже потом совмещает. Это нужно, когда нумерации разные или белки разные.

В нашем случае проверено, что нумерации обеих структур совпадают с UniProt, поэтому в скрипте пары строятся прямо по номерам остатков. Это точнее: исключается риск, что алгоритм выравнивания сместит рамку на похожем участке.

4.3 Итеративное отбрасывание и почему RMSD два

Одна подвижная петля может испортить всё наложение: алгоритм «тянет» оптимум, чтобы уменьшить её огромный вклад, и портит совмещение хорошо совпадающей части. Поэтому Matchmaker делает **iterative pruning**:

1. Совместить по всем парам, посчитать отклонения.
2. Выбросить пары с отклонением больше порога (по умолчанию 2,0 Å).
3. Совместить заново по оставшимся. Повторять до стабилизации.

В журнале появляются *два* числа: RMSD по всем парам и RMSD по оставшимся. Оба нужно записать — вместе они говорят больше, чем по отдельности. Большая разница между ними означает: «основная часть совпадает отлично, но есть локальные участки сильного расхождения».

5 Что именно сделано в работе, шаг за шагом

5.1 Инструменты

Задание написано под UCSF ChimeraX. На рабочей машине его нет, и поставить его в Python-окружение нельзя: ChimeraX — настольное приложение со своим интерпретатором, в PyPI его нет. Поэтому все операции выполнены через библиотеку `gemmi` (чтение mmCIF/PDB, работа с моделями и цепями) и `numpy` (линейная алгебра наложения), а в отчёте для каждого шага приведена эквивалентная команда ChimeraX.

Это не упрощение: все числа получены из тех же координат, которые прочитал бы ChimeraX, а наложение воспроизводит именно алгоритм Matchmaker, включая итеративное отбрасывание.

5.2 Шаг 1. Загрузка

Структуры скачаны напрямую с RCSB:

```
https://files.rcsb.org/download/2HYU.cif
https://files.rcsb.org/download/3QRJ.cif
```

и сохранены как `WT_original.cif` и `T315I_original.cif`.

5.3 Шаг 2. Выбор цепи

В 2HYU четыре цепи (A–D), в 3QRJ две (A, B). Все цепи в каждой структуре — один и тот же белок (одна полимерная сущность). Взята цепь A в обеих.

Почему именно A и почему вообще одна. Несколько цепей — это кристаллографическая копия, а не биологический комплекс: киназный домен ABL1 функционирует как мономер. Брать все четыре копии в докинг бессмысленно — это учетверит расчёт без новой информации. Цепь A выбрана как первая и, в 2HYU, наиболее полная.

5.4 Шаг 3. Проверка полноты

	2HYU, цепь A	3QRJ, цепь A
Разрешено остатков	263	258
Диапазон	235–498	234–496
Внутренние пропуски	275 (1 остаток)	274–278 (5 остатков)
Пропуски в сайте связывания	нет	нет

Пропуски попадают в границы киназного домена (242–493), но лежат в петле между $\beta 3$ и αC — она выходит на поверхность и в формировании кармана не участвует. Это проверено не на глаз: скрипт считает список остатков в радиусе 4,5 Å от лиганда и сверяет его с границами пропусков. Ни один контактный остаток не потерян.

5.5 Шаг 4. Поиск остатка 315 и проверка нумерации

Найдено: THR 315 в 2HYU, ILE 315 в 3QRJ, сдвиг нумерации 0 для обеих (см. раздел 3). Мутация присутствует в координатах, а не только в аннотации.

5.6 Шаг 5. Лиганд и сайт связывания

	2HYU	3QRJ
Ингибитор	иматиниб	ребастиниб (DCC-2036)
Код компонента	STI	919
Атомов (без H)	37	41
Контактных остатков ($\leq 4,5$ Å)	25	27

В обоих списках контактов присутствуют: остаток **315** (Thr или Ile), каталитический **Lys271**, шарнирные **Glu316–Phe317–Met318** и мотив **DFG** (Asp381–Phe382–Gly383). Это стандартный набор для АТР-кармана киназы — подтверждение, что лиганд сидит там, где ожидается, и что остаток 315 действительно образует стенку кармана, а не просто находится поблизости.

5.7 Шаг 6. Сохранение рабочих файлов

Для каждой формы сохранено по два файла:

Файл	Содержимое	Остатков	Атомов
WT_complex.pdb	цепь A + иматиниб	264	2110
WT_protein.pdb	цепь A, белок	263	2073
T315I_complex.pdb	цепь A + ребастиниб	259	2116
T315I_protein.pdb	цепь A, белок	258	2075

Зачем два варианта. Файл «белок + лиганд» нужен для **редокинга**: мы знаем экспериментальную позу ингибитора, запускаем докинг и смотрим, воспроизводит ли программа

эту позу. Если да — протоколу можно доверять. Файл «только белок» — это приёмник (receptor) для докинга новых молекул.

Почему без воды. Кристаллографическая вода в кармане — отдельная большая тема. Часть молекул воды структурно важна (опосредует водородные связи), часть — случайна. Стандартная практика — убирать воду и при необходимости возвращать отдельные молекулы осознанно. Поэтому в рабочих файлах воды нет.

5.8 Шаг 7. Наложение

Показатель	Значение
Пар остатков (общие номера)	257
RMSD по всем парам	1,292 Å
Итераций отбрасывания (порог 2,0 Å)	4
Пар после отбрасывания	242
RMSD после отбрасывания	0,815 Å
RMSD внутри киназного домена	1,301 Å (247 пар)
RMSD около остатка 315 (± 5)	0,920 Å (11 пар)
Отклонение C α остатка 315	0,386 Å

6 Главный результат и как его интерпретировать

6.1 Структуры почти одинаковы

0,815 Å по 242 парам — это уровень совпадения двух кристаллических форм одного и того же белка. Для сравнения: разные белки одного семейства дают 2–4 Å, а разные конформации одной киназы (DFG-in против DFG-out) — порядка 1,5–3 Å. Значит, замена Thr→Ile **не перестраивает укладку** киназного домена.

6.2 Но различия есть, и они не там, где мутация




Рис. 1: Отклонение $C\alpha$ по остаткам после наложения. Почти везде меньше 1 Å; выброс до 8 Å — остатки 389–400, то есть петля активации (381–405). В позиции 315 отклонение минимально (0,386 Å).

Наибольшие расхождения: остаток 398 — 7,95 Å, 397 — 7,82 Å, 399 — 5,59 Å, 396 — 5,10 Å, 390 — 4,78 Å. Все они лежат в петле активации 381–405 (границы взяты из UniProt, результат лабораторной №1).

Почему расходится именно петля активации. Это подвижный регуляторный элемент киназы: в активной конформации она развёрнута и формирует площадку для субстрата, в неактивной — сложена внутрь и блокирует карман. Её положение определяется тем, какой лиганд связан и в каких условиях рос кристалл. В 2HYU связан иматиниб (стабилизирует неактивную DFG-out конформацию), в 3QRJ — ребастиниб, другая молекула с другим способом связывания. То есть *крупнейшее различие между структурами вызвано разными лигандами, а не мутацией T315I*.

Это важно честно проговорить: мы сравниваем не «WT против T315I в одинаковых условиях», а две разные кристаллические структуры, которые отличаются сразу по двум параметрам — и мутацией, и связанным ингибитором. Разделить эти два вклада по имеющимся данным нельзя.

6.3 Почему глобальное RMSD обманчиво



Рис. 2: Thr315 и Ile315 после наложения. Основная цепь совпадает, но боковая цепь изолейцина разветвлена и уходит дальше в сторону кармана.

Три причины, по которым «RMSD 0,8 Å» не означает «карманы одинаковые»:

1. **Усреднение.** RMSD считается по 257 парам. Вклад одного остатка — порядка $\sqrt{1/257} \approx 6\%$; локальное изменение в нём просто растворяется.
2. **Считается по $C\alpha$, а меняется боковая цепь.** Отклонение $C\alpha$ остатка 315 — 0,386 Å, то есть *меньше* среднего по структуре. С точки зрения основной цепи «ничего не произошло». А объём боковой цепи вырос со ≈ 116 до ≈ 167 Å³ — именно это закрывает вход в гидрофобный карман и убирает донор водородной связи.
3. **Самое большое различие не связано с вопросом.** Петля активации расходится на 8 Å и формирует почти весь глобальный RMSD, хотя к механизму резистентности отношения не имеет.

Практический вывод: для оценки сайта связывания нужны локальные метрики — объём кармана, список контактов, геометрия водородных связей, — а не одно число по всей структуре.

7 Разбор кода

7.1 Структура проекта

Файл	Что делает
scripts/ prepare_structures.py	читает .cif, определяет цепь, пропуски, нумерацию, лиганд, сайт связывания; сохраняет шесть рабочих файлов
scripts/superpose.py	наложение Кабша, итеративное отбрасывание, RMSD
scripts/make_figures.py	иллюстрации по координатам
data/analysis.json	все числа первого скрипта
data/superposition.json	все числа второго, включая отклонение по каждому остатку

7.2 Поиск пропусков

Пропуск — это разрыв в нумерации подряд идущих разрешённых остатков:

```
def find_gaps(residues):  
    # residues is a sorted list of (seqid, resname)  
    gaps = []  
    for (n1, _), (n2, _) in zip(residues, residues[1:]):  
        if n2 > n1 + 1:  
            gaps.append((n1 + 1, n2 - 1))  
    return gaps
```

7.3 Остатки сайта связывания

Для каждого остатка белка ищем минимальное расстояние до любого атома лиганда:

```
def contact_residues(chain, ligand, cutoff):  
    lig_pos = [atom.pos for atom in ligand]  
    hits = []  
    for res in chain:  
        best = None  
        for atom in res:  
            for lp in lig_pos:  
                d = atom.pos.dist(lp)  
                if best is None or d < best:  
                    best = d  
        if best is not None and best <= cutoff:  
            hits.append((res.seqid.num, res.name, round(best, 2)))  
    return hits
```

Порог 4,5 Å — стандартный для «первой координационной сферы»: он захватывает водородные связи (2,6–3,2 Å) и ван-дер-ваальсовы контакты (3,4–4,2 Å), но не притягивает далёкие остатки.

7.4 Наложение Кабша

```
def kabsch(P, Q):
    pc, qc = P.mean(axis=0), Q.mean(axis=0)
    H = (P - pc).T @ (Q - qc)
    U, _, Vt = np.linalg.svd(H)
    d = np.sign(np.linalg.det(Vt.T @ U.T)) # forbid reflection
    D = np.diag([1.0, 1.0, d])
    R = Vt.T @ D @ U.T
    return R, qc - R @ pc
```

Строка с `d` существенна: без неё SVD может выдать матрицу с определителем -1 , то есть зеркальное отражение. Оно формально уменьшило бы RMSD, но соответствовало бы физически невозможной (зеркальной) молекуле.

7.5 Итеративное отбрасывание

```
keep = np.ones(len(common), dtype=bool)
for it in range(1, 21):
    R, t = kabsch(P[keep], Q[keep])
    P_fit = (R @ P.T).T + t
    dev = np.linalg.norm(P_fit - Q, axis=1)
    new_keep = dev <= PRUNE_CUTOFF
    if new_keep.sum() < 3 or (new_keep == keep).all():
        break
    keep = new_keep
```

Выход из цикла — когда набор перестал меняться (сошлось) или когда пар осталось слишком мало. У нас сошлось за 4 итерации: 257 пар $\rightarrow$ 242.

8 Как повторить всё с нуля

```
cd d:\uni\karpenka_labs\lab2

# 1. download structures (2HYY, 3QRJ) into structures/
curl -o structures/2hyy.cif https://files.rcsb.org/download/2HYY.cif
curl -o structures/3qrj.cif https://files.rcsb.org/download/3QRJ.cif

# 2. analyse and build the six working files
..\venv\Scripts\python.exe scripts\prepare_structures.py

# 3. superposition and RMSD
..\venv\Scripts\python.exe scripts\superpose.py

# 4. figures
..\venv\Scripts\python.exe scripts\make_figures.py

# 5. documents (twice each)
cd report && pdflatex report.tex && pdflatex report.tex
cd ..\guide && pdflatex guide.tex && pdflatex guide.tex
```

Окружение — общий `venv` лабораторных `karpenka_labs/.venv` (Python 3.14; `gemmi`, `numpy`, `matplotlib`, `requests`, `openpyxl`). Первый скрипт читает `lab1/data/uniprot_P00519.json`, поэтому папка `lab1` должна лежать рядом.

Если делать в ChimeraX. Последовательность команд приведена в отчёте для каждого пункта. Полный сценарий:

```
open WT_original.cif
info #1
cartoon #1/A
hide #1/A atoms
select #1/A:315
show sel atoms
style sel stick
select #1:STI
show sel atoms
style sel stick
select clear
select (#1/A & protein) | (#1:STI)
save WT_complex.pdb models #1 selectedOnly true
select clear
select #1/A & protein
save WT_protein.pdb models #1 selectedOnly true
close session
open WT_original.cif
open T315I_original.cif
matchmaker #2/A to #1/A pairing ss
select #1/A:315 | #2/A:315
show sel atoms
style sel stick
```

Для T315I те же команды с заменой STI на 919 и имён файлов.

9 Честные ограничения работы

1. **Сравниваются структуры с разными лигандами.** 2HYU содержит иматиниб, 3QRJ — ребастиниб. Поэтому разделить вклад мутации и вклад лиганда в наблюдаемые различия невозможно. Корректнее было бы сравнивать WT и T315I с одним и тем же ингибитором, но такой пары среди человеческих структур нет.
2. **Разные разрешения.** 2,40 против 1,82 Å. Часть различий в положении боковых цепей может объясняться точностью, а не реальной разницей.
3. **RMSD считался по C α .** Это стандарт, но он нечувствителен к изменениям боковых цепей — то есть ровно к тому, что составляет суть мутации.
4. **Межатомные взаимодействия не анализировались.** Водородные связи, гидрофобные контакты, объём кармана — предмет следующей работы. Здесь показано лишь, что остаток 315 входит в сайт связывания.
5. **Иллюстрации построены не в ChimeraX.** Геометрия в них настоящая (те же координаты), но это схематичные проволочные представления, а не рендеринг молекулярного вьюера: нет лент вторичной структуры, поверхностей и освещения.
6. **Взята одна цепь из нескольких.** Цепи A, B, C, D в 2HYU слегка различаются; мы не проверяли, насколько выбор цепи A влияет на геометрию кармана.

10 Вероятные вопросы на защите

Почему для работы берут только киназный домен, а не весь белок?

Полноразмерный BCR::ABL1 (≈ 2000 а.о. для p210) не закристаллизован. Патологической является именно киназная активность, и все АТР-конкурентные ингибиторы связываются в кармане киназного домена. Структурно охарактеризован только он.

Что такое gatekeeper и почему он так называется?

Остаток на границе между АТР-карманом и более глубокой гидрофобной полостью (back pocket). Размер его боковой цепи определяет, пройдёт ли туда ингибитор: малый Thr оставляет проход открытым, крупный Ile закрывает. Отсюда «привратник».

Почему в структуре нет части остатков?

Подвижные участки не дают регулярного вклада в электронную плотность, и вписать туда атомы невозможно. В последовательности они есть, координат нет.

Почему Matchmaker выдаёт два значения RMSD?

Первое — по всем парам, второе — после итеративного отбрасывания пар с отклонением больше $2 \text{ \AA}$. Большая разница между ними означает, что расхождение создаётся небольшим числом локальных участков, а не всей структурой. У нас: $1,292 \text{ \AA}$ по 257 парам и $0,815 \text{ \AA}$ по 242.

RMSD $0,8 \text{ \AA}$ — значит, структуры идентичны?

Нет. RMSD усредняет по сотням остатков и считается по $C\alpha$. Отклонение $C\alpha$ остатка 315 — всего $0,386 \text{ \AA}$, хотя именно там находится мутация: меняется боковая цепь, а не положение основной. Судить о кармане по глобальному RMSD нельзя.

Где самые большие различия и почему?

В остатках 389–400 (до $7,95 \text{ \AA}$) — это петля активации 381–405. Её конформация зависит от связанного лиганда и условий кристаллизации. Поскольку в двух структурах разные ингибиторы, различие вызвано в первую очередь этим, а не мутацией.

Зачем сохранять отдельно «белок» и «белок + лиганд»?

Комплекс — для редокинга: проверить, воспроизводит ли протокол известную экспериментальную позу. Только белок — как приёмник для докинга новых молекул.

Почему убрали воду?

Часть кристаллографической воды структурно значима, часть случайна, и отличить их по одной структуре трудно. Стандартная практика — убрать всю и при необходимости вернуть отдельные молекулы осознанно.

Как убедились, что в 3QRJ только одна мутация?

Сопоставлением с последовательностью UniProt: совпало 257 остатков из 258, и единственное несовпадение — позиция 315 (T в UniProt, I в структуре). Будь других замен больше, несовпадений было бы больше.

Чем mmCIF лучше PDB?

PDB — формат с фиксированной шириной колонок, он ломается при числе атомов больше 99999 и числе цепей больше 62, и в нём негде хранить расширенные метаданные. mmCIF — таблицы без этих ограничений; RCSB считает его основным.

11 Выводы

1. Обе выбранные в первой работе структуры пригодны для дальнейшего анализа: нумерация совпадает с UniProt (сдвиг 0), сайт связывания разрешён полностью, посторонних мутаций нет, ингибитор присутствует в обеих.

2. Получено шесть рабочих файлов (по три на форму) с прослеживаемой цепочкой преобразования от записи RCSB.
3. Глобальная укладка WT и T315I совпадает: RMSD 0,815 Å по 242 парам Cα после итеративного отбрасывания (1,292 Å по всем 257 парам).
4. Мутация не перестраивает укладку: отклонение Cα остатка 315 — 0,386 Å, меньше среднего по структуре.
5. Наибольшие различия (до 7,95 Å) сосредоточены в петле активации 389–400 и объясняются в первую очередь разными связанными лигандами, а не мутацией.
6. Глобальное RMSD не является доказательством идентичности сайта связывания: оно усредняет по всей цепи и не видит изменений боковых цепей. Для кармана нужны локальные метрики — это задача следующей работы.